Laporan Tugas P6 Machine Learning: Klasifikasi dan Clustering pada Dataset Penyakit Jantung

Nama: Daffa Rizqi Wandika | NPM: 232310024 | Kelas: TI-23-PA

1. Pendahuluan

Laporan ini merangkum seluruh langkah pada tugas P6, mulai dari identifikasi atribut, praproses data, pembangunan model klasifikasi, sampai pembangunan model clustering. Dataset yang dipakai adalah *heart_modified.csv* yang berisi 918 baris data pasien dengan 11 atribut prediktor dan 1 atribut label, yaitu HeartDisease (1 berarti terdapat penyakit jantung, 0 berarti tidak). Seluruh pengerjaan dilakukan dengan Python di Google Colab memakai pustaka pandas, scikit-learn, matplotlib, dan seaborn.

2. Nama dan Jenis Atribut

Jenis atribut ditentukan dari jumlah nilai unik pada setiap kolom. Atribut dengan banyak nilai unik yang kontinu dikelompokkan sebagai numerik, sedangkan atribut dengan sedikit nilai unik dikelompokkan sebagai kategorik. Atribut FastingBS dan HeartDisease hanya bernilai 0 atau 1, sehingga dikelompokkan sebagai kategorik biner.

No	Nama Atribut	Peran	Jenis	Keterangan / Nilai Unik
1	Age	Prediktor	Numerik	Usia pasien (tahun)
2	Sex	Prediktor	Kategorik	M, F
3	ChestPainType	Prediktor	Kategorik	TA, ATA, NAP, ASY
4	RestingBP	Prediktor	Numerik	Tekanan darah saat istirahat (mm Hg)
5	Cholesterol	Prediktor	Numerik	Kadar kolesterol serum (mg/dl)
6	FastingBS	Prediktor	Kategorik biner	0, 1 (gula darah puasa lebih dari 120 mg/dl)
7	RestingECG	Prediktor	Kategorik	Normal, ST, LVH
8	MaxHR	Prediktor	Numerik	Detak jantung maksimum
9	ExerciseAngina	Prediktor	Kategorik	Y, N
10	Oldpeak	Prediktor	Numerik	Depresi segmen ST akibat olahraga
11	ST_Slope	Prediktor	Kategorik	Up, Flat, Down

No	Nama Atribut	Peran	Jenis	Keterangan / Nilai Unik
12	HeartDisease	Label	Kategorik biner	0, 1

Jumlah nilai unik pada atribut numerik adalah Age 50, RestingBP 67, Cholesterol 219, MaxHR 119, dan Oldpeak 53. Atribut kategorik hanya memiliki 2 sampai 4 nilai unik.

3. Praproses Data dan Statistik Deskriptif

Praproses dilakukan dalam urutan berikut.

Pertama, dataset dipisahkan menjadi atribut prediktor (X) yang berisi 11 kolom dan label (y) yang hanya berisi kolom HeartDisease. Salinan X sebelum praproses disimpan agar statistik deskriptif sebelum dan sesudah praproses dapat dibandingkan.

Kedua, missing value pada atribut numerik (Age, RestingBP, Cholesterol, MaxHR, Oldpeak) diisi dengan nilai rata-rata menggunakan *SimpleImputer* dengan strategi *mean*, sesuai ketentuan soal. Jumlah missing value per kolom sebelum imputasi adalah sebagai berikut: RestingBP sebanyak 18, Cholesterol sebanyak 18, dan MaxHR sebanyak 18, sedangkan kolom lainnya tidak memiliki missing value. Setelah imputasi, seluruh kolom tidak lagi memiliki missing value.

Ketiga, atribut numerik diubah skalanya dengan *StandardScaler* sehingga setiap kolom memiliki rata-rata mendekati 0 dan simpangan baku 1. Atribut FastingBS tidak ikut diubah skalanya karena merupakan atribut biner.

Praproses tambahan yang dilakukan adalah *One-Hot Encoding* pada atribut kategorik (Sex, ChestPainType, RestingECG, ExerciseAngina, dan ST_Slope) dengan opsi *drop_first*, agar atribut tersebut dapat diproses oleh algoritma klasifikasi dan clustering yang hanya menerima nilai angka. Setelah proses ini, jumlah kolom prediktor bertambah menjadi 15 kolom.

Statistik deskriptif sebelum praproses

Atribut	Jumlah Data	Rata-rata	Simpangan Baku	Minimum	Maksimum
Age	918	53,51	9,43	28	77
RestingBP	900	132,41	18,61	0	200
Cholesterol	900	199,25	109,64	0	603
MaxHR	900	136,87	25,56	60	202
Oldpeak	918	0,89	1,07	-2,6	6,2

Statistik deskriptif setelah praproses

Atribut	Jumlah Data	Rata-rata	Simpangan Baku	Minimum	Maksimum
Age	918	sekitar 0	1,0005	-2,71	2,49
RestingBP	918	sekitar 0	1,0005	-7,19	3,67
Cholesterol	918	sekitar 0	1,0005	-1,84	3,72
MaxHR	918	sekitar 0	1,0005	-3,04	2,58
Oldpeak	918	sekitar 0	1,0005	-3,27	4,98

Pembahasan: sebelum praproses, atribut numerik memiliki rentang nilai yang sangat berbeda. Misalnya Cholesterol bernilai ratusan, sedangkan Oldpeak hanya bernilai satuan. Perbedaan rentang ini dapat membuat atribut dengan nilai besar mendominasi perhitungan jarak pada algoritma seperti clustering. Setelah praproses, semua atribut numerik berada pada skala yang sebanding, dengan rata-rata mendekati 0 dan simpangan baku mendekati 1. Pada kolom yang tadinya memiliki missing value, jumlah data (*count*) menjadi lengkap karena nilai yang kosong sudah terisi rata-rata. Sebelum imputasi, RestingBP, Cholesterol, dan MaxHR hanya memiliki 900 data dari 918 baris karena masing-masing 18 nilainya kosong. Terdapat pula nilai minimum 0 pada RestingBP dan Cholesterol, yang secara medis tidak wajar dan kemungkinan merupakan data yang tidak tercatat. Nilai 0 ini tetap diperlakukan sebagai data biasa pada praproses, sehingga ikut memengaruhi rata-rata, hasil penskalaan, dan hasil clustering.

4. Model Klasifikasi

Algoritma yang digunakan adalah *Decision Tree* dengan parameter max_depth = 3 dan random_state = 42. Kedalaman pohon dibatasi agar model tidak terlalu rumit dan pohonnya masih mudah dibaca.

Pembagian data memakai metode *holdout* dengan proporsi 85% data training dan 15% data testing (test_size = 0.15), dengan opsi *stratify* agar proporsi kelas 0 dan 1 tetap sama pada kedua bagian. Dari 918 baris, terdapat sekitar 780 data training dan 138 data testing.

Hasil evaluasi pada data testing:

- Akurasi: 0,7971 (79,71%), yaitu 110 dari 138 data testing diprediksi dengan benar
- Confusion matrix: 51 pasien tidak sakit diprediksi tidak sakit, 11 pasien tidak sakit diprediksi sakit, 17 pasien sakit diprediksi tidak sakit, dan 59 pasien sakit diprediksi sakit
- Precision, recall, dan f1-score: kelas 0 (tidak sakit) memiliki precision 0,75, recall 0,82, dan f1-score 0,78 dari 62 data. Kelas 1 (sakit) memiliki precision 0,84,

recall 0,78, dan f1-score 0,81 dari 76 data. Rata-rata makro untuk ketiganya adalah 0,80

Pembahasan: akurasi menunjukkan seberapa banyak data testing yang diprediksi benar. Confusion matrix memperlihatkan jenis kesalahannya. Pada kasus penyakit jantung, kesalahan *false negative*, yaitu pasien yang sebenarnya sakit tetapi diprediksi sehat, merupakan kesalahan yang paling perlu diperhatikan, sehingga nilai recall untuk kelas 1 penting untuk dicermati. Akurasi sekitar 80% tergolong cukup baik untuk pohon yang kedalamannya hanya dibatasi 3 tingkat. Kesalahan yang paling sering adalah 17 pasien sakit yang diprediksi sehat, lebih banyak daripada 11 pasien sehat yang diprediksi sakit. Recall kelas 1 sebesar 0,78 berarti sekitar 22% pasien sakit tidak terdeteksi, sedangkan precision kelas 1 sebesar 0,84 berarti sebagian besar pasien yang diprediksi sakit memang sakit. Pohon keputusan juga divisualisasikan sehingga aturan pemisahan di setiap node dapat dibaca langsung. Node teratas memakai atribut ST_Slope_Up (gini 0,494 pada 780 data training). Pasien yang ST_Slope-nya bukan Up (449 data, 373 di antaranya sakit) dipisah lagi berdasarkan MaxHR, sedangkan pasien dengan ST_Slope Up (331 data, 272 di antaranya sehat) dipisah lagi berdasarkan Cholesterol. Atribut lain yang dipakai pohon adalah Sex, ChestPainType, FastingBS, dan ExerciseAngina. Batas Cholesterol sebesar -1,445 (setelah penskalaan) memisahkan pasien yang kolesterolnya bernilai 0 dari pasien lainnya, sehingga nilai 0 yang tidak wajar tadi ikut memengaruhi pohon.

5. Model Clustering

Pada tahap ini clustering dilakukan pada atribut prediktor hasil praproses (hasil *One-Hot Encoding*) tanpa memakai label. Dua algoritma dicoba.

Percobaan awal: DBSCAN

DBSCAN dicoba dengan beberapa kombinasi parameter eps dan min_samples. Hanya kombinasi yang menghasilkan minimal dua klaster dan noise tidak lebih dari 50% data yang dianggap valid. Titik noise tidak dihitung pada SSE dan silhouette score.

eps	min_samples	Jumlah klaster	Jumlah noise	Silhouette
1,5	3	7	248	-0,0977
1,5	8	3	381	-0,0239
1,5	10	2	438	0,1806
1,6	3	8	177	-0,0850
1,7	3	7	125	-0,0683

Kombinasi terbaik adalah eps = 1,5 dan min_samples = 10 dengan 2 klaster, silhouette score 0,1806, dan SSE 2269,8575. Namun, kombinasi ini menganggap 438 data (sekitar 48%) sebagai noise, dan empat kombinasi lainnya memiliki silhouette negatif.

Hal ini menunjukkan bahwa DBSCAN kurang cocok untuk data ini, karena data berdimensi cukup tinggi dan tidak memiliki wilayah padat yang terpisah jelas.

Model akhir: Agglomerative Clustering

Karena DBSCAN membuang hampir separuh data sebagai noise, model akhir yang dipilih adalah *Agglomerative Clustering* dengan *linkage* ward. Metode ini mengelompokkan seluruh data tanpa noise, sehingga SSE dan silhouette score dihitung dari seluruh 918 data. Jumlah klaster dicoba dari 2 sampai 8 dan dipilih yang silhouette score-nya tertinggi, yaitu k = 3.

Hasil model akhir:

- Jumlah klaster: 3
- SSE: 4459,4232
- Silhouette score: 0,1904
- Jumlah data per klaster: 371, 377, dan 170

Pembahasan: nilai silhouette score 0,1904 tergolong rendah, artinya klaster yang terbentuk belum terpisah tegas dan masih ada tumpang tindih. Hal ini wajar karena data bersifat campuran (numerik dan kategorik) dan kelompok pasien pada dataset ini tidak memiliki batas yang jelas. Ukuran ketiga klaster cukup seimbang. Jumlah tiga klaster tidak harus sama dengan jumlah kelas label (dua), karena clustering tidak memakai label dan mengelompokkan pasien hanya berdasarkan kemiripan atribut. Nilai SSE tidak dapat dibandingkan langsung dengan SSE DBSCAN, karena SSE DBSCAN hanya menghitung titik non-noise. Profil ketiga klaster dari data asli (sebelum penskalaan) ditampilkan pada tabel berikut.

Klaster	Jumlah Data	Age	Resting BP	Cholesterol	MaxHR	Oldpeak	FastingBS	HeartDisease = 1
0	371	57,37	137,32	247,36	127,57	1,62	0,23	79,5%
1	377	48,51	128,86	241,27	152,63	0,20	0,11	17,0%
2	170	56,18	129,57	1,09	122,25	0,81	0,51	87,6%

Klaster 0 berisi pasien yang paling tua dengan detak jantung maksimum rendah dan Oldpeak tinggi. Sebanyak 70,6% mengalami nyeri dada tipe ASY, 68,5% mengalami angina saat olahraga, dan 80,6% memiliki ST_Slope Flat. Penyakit jantung ditemukan pada 79,5% anggotanya, sehingga klaster ini dapat disebut kelompok berisiko tinggi.

Klaster 1 berisi pasien yang paling muda dengan detak jantung maksimum tertinggi dan Oldpeak paling rendah. Hanya 9,0% yang mengalami angina saat olahraga, 83,6%

memiliki ST_Slope Up, dan penyakit jantung ditemukan pada 17,0% anggotanya, sehingga klaster ini dapat disebut kelompok berisiko rendah.

Klaster 2 memiliki rata-rata Cholesterol hanya 1,09, artinya hampir semua anggotanya bernilai kolesterol 0, yang kemungkinan adalah data tidak tercatat. Anggotanya didominasi laki-laki (94,1%) dan 87,6% mengalami penyakit jantung. Klaster ini terbentuk terutama karena nilai kolesterol 0 tersebut, bukan karena kemiripan kondisi pasien secara menyeluruh. Hal ini menjadi salah satu alasan nilai silhouette score rendah.

6. Kesimpulan

Dataset terdiri dari 11 atribut prediktor (5 numerik dan 6 kategorik, termasuk FastingBS yang biner) dan 1 label biner. Praproses berupa imputasi rata-rata, *StandardScaler*, dan *One-Hot Encoding* membuat data siap dipakai oleh model. Model klasifikasi *Decision Tree* menghasilkan akurasi 0,7971 (79,71%) pada data testing. Pada clustering, DBSCAN menghasilkan silhouette 0,1806 tetapi membuang sekitar 48% data sebagai noise, sehingga dipilih *Agglomerative Clustering* dengan 3 klaster yang memiliki silhouette 0,1904 dan SSE 4459,4232. Struktur klaster pada data ini tergolong lemah, sehingga hasil clustering sebaiknya dibaca sebagai gambaran kelompok pasien secara umum, bukan pemisahan yang tegas.